

# Raport de Cercetare

Stefan Contiu

Semestrul I, Februarie 2015

Master Inteligenta si Viziune Artificiala – UTCN

## Idei identificate in literatura de specialitate

Activitatea de cercetare din Semestrul I s-a concentrat pe studierea **rețelelor neuronale artificiale** si aplicarea lor in diverse procese din **domeniul agriculturii**. Studiul s-a facut cu precadere pe metode ce folosesc achizitii bazate pe imagini **hyper si multi-spectrale**.

Retelele neuronale au fost folosite cu succes pentru **determinarea nivelului de azot al porumbului** prin intermediul imaginilor multi-spectrale. Modelul rețelei neuronale folosite contine 3 noduri de intrare(nivelul de verde, rosu si near-infrared), un nod de iesire(ce reprezinta nivelul clorofilei) si un nivel de noduri ascunse. S-a folosit backpropagation pentru antrenarea rețelei, fara regularizare. Autorii conclud ca rezultatele sunt mult mai bune decat in cazul folosirii regresiei liniare.

Retelele neuronale se pot folosi la **clasificarea diferitelor tipuri de culturi agricole** din imagini provenite de la sateliti. Pentru aceasta s-a folosit o retea neuronală cu unu sau doua starturi ascunse. Parametri de invatare au fost stabiliti printr-o tehnica de "trail and error". S-a constatat ca se poate imbunatati calitatea prezicerilor prin folosirea reducerii dimensionalitatii (de la 8D la 2D sau 3D), analiza histogramei sau adaugarea de noi pixeli in imagini. Autorii au reusit sa obtina o acuratete de 95.3% in clasificare.

Imaginile hyper-spectrale si multi-spectrale pot fi folosite cu succes in **evaluarea calitatii si sigurantei hranei**. Exista diferite tipuri de mecanisme pentru achizitia informatiilor vizuale: scanarea unui punct(prin spectro-photometer), scanarea unei linii(prin spectrgraph) sau scanarea unei suprafete(spectral-scan). Este necesar un proces de calibrare la nivelul spectral, spatial si al imaginii. Formatul imaginii se poate defini prin BIP(Band Interleaved by Pixel), BIL(Band Intervleaved by Line) sau BSQ(Band Sequential). Aceste imagini se pot precesa mai departe pentru corectia zgomotului sau reducerea dimensionalitatii spectrale(prin Principal Component Analysis, Partial Least Squares sau Retele Neuronale).

Imaginile traditionale, hyper si multi spectrale se pot folosi pentru **inspectia externa a calitatii a fructelor si legumelor**. Dupa aplicarea etapelor standard in procesarea imaginilor de intrare

(pre-procesare, segmentare si clasificare, extragerea trasaturilor) s-a ajuns la faza de analiza si recunoasterea defectelor. Aplicatiile consta in inspectia culorii, texturii, marimii, formei si suprafetei.

### **Teme alese pentru studiu viitor**

1. **Clasificarea stadiului culturilor** pe baza observatiilor facute din imagini hyper si multi-spectrale. Observarea si monitorizarea stadiului culturilor este de o importanta majora pentru securitatea hranei. Acest lucru poate avea un impact direct in prevenirea crizelor alimentare in tarile sub-dezvoltate sau in curs de dezvoltare.
2. Aprofundarea metricilor si evaluarea performantei clasificatorilor bazati pe retele neuronale.

### **Posibile unelte/instrumentatii conceptuale ce pot fi aplicate**

**Matlab** prin intermediul **Neural Network Toolbox** ofera functionalitati si aplicatii pentru modelarea de sisteme complexe nonliniare. Suporta atat Supervised Learning(prin feed-forward, radial-basis si dynamic networks) cat si Unsupervised Learning(prin competitive layers si self-organizing maps). Cu ajutorul acestei unelte se poate face design-ul, antrenamentul, vizualizarea si simularea retelelor neuronale. Unul din marile avantaje e optimizarea pentru date de marime foarte mare. Calculele si datele se pot distribui pe procesoare multi-core, pe Graphics Processing Units, sau clustere de calculatoare folosind calcul paralel (<http://www.mathworks.com/products/neural-network/>).

**Octave** este o alternativa gratuita si Open Source pentru Matlab. Are o sintaxa compatibila aproape in totalitate cu Matlab. Pentru suportul retelelor neuronale contine o extensie (**nnet**) ce foloseste feed-forward (<https://www.gnu.org/software/octave/>).

**Cuda-Convnet** este o librarie ce ofera o implementare C++/CUDA pentru retele convolutionale(feed-forward). Invatarea se face folosind back-propagation algorithm (<https://code.google.com/p/cuda-convnet/>).

**Caffe** este un framework pentru deep-learning folosit in special pentru clasificarea imaginilor. Retelele sunt specificate in fisiere de configurari, fara parametri codati in fisierele cu cod. Ruleaza pe CPU si GPU. Are o performanta considerabila de procesare, creatorii(Berkley Vision and Learning Center) sustinand ca este cea mai performanta(rapida) implementare pentru Convolutional Neural Networks existenta(<http://caffe.berkeleyvision.org/>).

**OpenCV** este o librarie cu interfete pentru C/C++/Python si Java optimizata in special pentru procesarea imaginilor (<http://opencv.org/>).