

Clasificarea si vizualizarea culturilor agricole din imagini satelitare hyper/multi spectru

Stefan Contiu

Universitatea Tehnica din Cluj-Napoca

Email: stefan.contiu@gmail.com

Abstract—Obiectivul acestui studiu este construirea unui sistem ce intruneste clasificarea diferitelor tipuri de culturi agricole si vizualizarea rezultatelor in cadrul unei aplicatii interactive. Clasificarea se realizeaza printr-un algoritm de invatare supervizata folosind retele neuronale artificiale, datele de antrenament provenind din imagini satelitare multi-spectrale oferite de satelitul Landsat 7 ETM+. Aplicatia interactiva este construita avand in vedere maximizarea uzuabilitatii, astfel incat experienta utilizatorilor sa fie foarte satisfacatoare.

Index Terms—agricultura, clasificare, imagini multi-spectru, retele neuronale, uzuabilitate.

I. INTRODUCERE

Monitorizarea culturilor agricole este cruciala in prevenirea crizelor de hrana in tarile sub-dezvoltate. Lucrarea propune automatizarea acestui proces prin utilizarea imaginilor satelitare multi-spectrale, a unui algoritm de clasificare bazat pe retele neuronale artificiale si o aplicatie Web interactiva prin care utilizatorii pot vizualiza rezultatele.

Imaginile multi-spectrale sunt folosite cu succes in domeniul agriculturii de precizie datorita informatiilor extinse ce le ofera fata de imagistica traditionala. In aceasta lucrare folosim ca si sursa imagini multi-spectrale provenite de la satelitul Landsat 7+ ETM. Dupa o faza de pre-procesare, echivalenta cu extragerea trasaturilor, se continua cu clasificarea culturilor dupa diferite categorii. Aceasta clasificare se face prin antrenarea unui model bazat pe retele neuronale artificiale. Modelul contine un set de parametrii specifici (ca de exemplu rata de invatare sau ponderile din retea) care trebuie determinati pentru maximizarea acuratetei predictiei.

Aplicatia interactiva aplica cunostintele dobandite prin algoritmul de invatare supervizata asupra unor zone de interes alese de utilizatori. Astfel, se vor putea vizualiza rezultatele pentru o anumita locatie geografica si pentru o anumita perioada de timp. Datele sunt prezentate atat in format grafic cat si in format tabelar.

Pentru realizarea acestui sistem, propunem o arhitectura bazata pe 3 nivele: interfata aplicatiei interactive, un nivel de servicii si un nivel al datelor. O asemenea separare permite scalabilitatea sistemului si folosirea de catre alte sisteme software(parti tertie) doar a unui subset al serviciilor sau datelor.

Este important ca aplicatia interactiva sa respecte un design care ridica nivelul uzuabilitatii pentru diferitele categorii de utilizatori. Pentru aceasta, vom prezenta o analiza a celor 10 cerinte euristice formulate de Nielsen[1] in capitolul V-B.

II. ALTE REALIZARI

In [2] se prezinta o clasificare a diferitelor tipuri de culturi agricole din imagini provenite de la sateliti. Pentru aceasta s-a folosit o retea neuronală cu unu sau doua starturi ascunse. Parametri de invatare au fost stabiliti printr-o tehnica de trail and error. S-a constatat ca se poate imbunatati calitatea prezicerilor prin folosirea reducerii dimensionalitatii (de la 8D la 2D sau 3D), analiza histogramei sau adaugarea de noi pixeli in imagini. Autorii au reusit sa obtina o acuratete de 95.3 in clasificare.

Retelele neuronale au fost folosite cu succes pentru determinarea nivelului de azot al porumbului prin intermediul imaginilor multi-spectrale[3]. Modelul retelei neuronale folosite contine 3 noduri de intrare(nivelul de verde, rosu si near-infrared), un nod de iesire (ce reprezinta nivelul clorofilei) si un nivel de noduri ascunse. S-a folosit backpropagation pentru antrenarea retelei, fara regularizare. Autorii conclud ca rezultatele sunt mult mai bune decat in cazul folosirii regresiei liniare.

Imaginile hyper-spectrale si multi-spectrale pot fi folosite cu succes in evaluarea calitatii si sigurantei hranei[4]. Exista diferite tipuri de mecanisme pentru achizitia informatiilor vizuale: scanarea unui punct(prin spectro-photometer), scanarea unei linii(prin spectrgraph) sau scanarea unei suprafete(spectral-scan). Este necesar un proces de calibrare la nivelul spectral, spatial si al imaginii. Formatul imaginii se poate defini prin BIP(Band Interleaved by Pixel), BIL(Band Intervleaved by Line) sau BSQ(Band Sequential). Aceste imagini se pot prexesa mai departe pentru corectia zgomotului sau reducerea dimensionalitatii spectrale(prin Principal Component Analysis, Partial Least Squares sau Rețele Neuronale).

Imaginile traditionale, hyper si multi spectrale se pot folosi pentru inspectia externa a calitatii a fructelor si legumelor[5]. Dupa aplicarea etapelor standard in procesarea imaginilor de intrare (pre-procesare, segmentare si clasificare, extragerea trasaturilor) s-a ajuns la faza de analiza si recunoasterea defectelor. Aplicatiile consta in inspectia culorii, texturii, marimii, formei si suprafetei.

III. CONSIDERATII TEORETICE

A. Utilizarea imaginilor hyper/multi spectru in domeniul agriculturii

Datele folosite pentru detectia culturilor au fost obtinute prin teledetectie prin intermediul satelitului Landsat 7 ETM+.

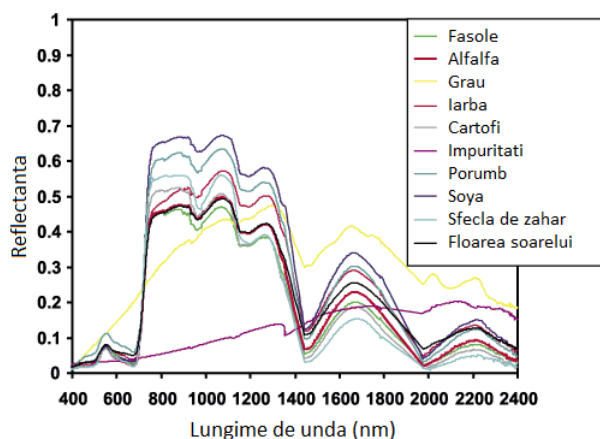


Fig. 1. Semnatura spectrala pentru diferite culturi agricole [6]

Acest satelit a fost lansat in Aprilie 1999 si este inca in functionare. Satelitul este echipat cu senzori pasivi multispectrali ce masoara energia, in forma undelor usoare provenite de la soare. Cand aceasta energie intampina plantele este reflectata, absorbita sau transmisa prin mai multe feluri depinzand de lungimile de unda, tipul si conditia plantei. Aceste interactiuni dau nastere unor semnat-uri spectrale pentru diferitele specii de plante. Semnat-urile variaza pentru acelasi tip de specie(sau cultura) in functie de timp, de exmplu semnat-ura obtinuta cand apar puietii sau rasadurile este diferita fata de cea cand planta este la maturitate sau pe finalul ciclului de viata. Figura (1) prezinta semnat-urile spectrale pentru diferite tipuri de culturi.

Principalul mijloc pentru discriminarea diferitelor tipuri de culturi este calcularea unui raport, denumit NDVI (*Normalized Difference Vegetation Index*) considerand cantitatea de infrarosu reflectata de planta. Formula se foloseste de benzile rosu(*Red*) si aproape de infrarosu(*NIR*):

$$NDVI = \frac{NIR - Red}{NIR + Red}$$

NDVI este folositor pentru vegetatie deoarece vegetatia in crestere are varful de reflectanta in portiunea aproape-de infrarosu a spectrului electromagnetic. Mai concret, frunzele verzi au o reflectanta in intervalul 0.5, 0.7 (verde la rosu) si 0.7, 1.3(aproape infrarosu). Aceste valori de reflectanta sunt rapoarte ce iau valori intre 0.0 si 1.0. Deci NDVI variaza intre -1.0 si +1.0 (ESRI 2013). Valori negative pentru NDVI sunt caracteristice pentru apa adanca. Valorile din preajma lui 0 (de la -0.1 la 0.1) corespund suprafetelor cu roci, nisip sau zapada. Valori pozitive mici (de la 0.2 la 0.4) corespund arbusitilor si pasunilor. Valori mai mari(ce se apropie de 1) indica suprafete temperate si tropicale. Intervalul standard pentru NDVI este de la -0.1 (nu foarte verde) la 0.6 (suprafata foarte verde).

B. Antrenare modelului de clasificare a culturilor

Pentru construirea setului de date de antrenament, pe langa Landsat 7 ETM+, s-au folosit clasificari deja existente, necesare pentru valorile de adevar(ground truth). Acestea au fost obtinute de la "U.S. National Agricultural Statistics Service" prin accesarea site-ului web :

<http://nassgeodata.gmu.edu/CropScape/>. Acest web-site permite definirea unei sectiuni de interes pentru care ofera date in rapoarte grafice sau tabelare cu privire la culturile agricole, sub categoria: "Cropland Data Layers."

Retelele neuronale artificiale(RNA) sunt modele computa-tionale care sunt folosite pentru esitmarea sau aproximarea functiilor non-liniare ce depind de un numar mare de intrari. Pe langa adaptibilitatea si abilitatea de a produce rezultate de calitate pentru seturi de intrare mari, cu zgomot sau incomplete, RNA sunt eficiente in identificarea pattern-urilor si a structurilor ascunse in date multi-dimensionale, ca si cele obtinute prin tele-detectie[7]. Elementul de baza al unei retele neuronale este un nod de procesare ce corespunde neuronului din creierul uman. Acest nod primeste o multime de valori ca intrare pe care le insumeaza ponderat. Mai apoi valoarea sumei este trecuta printr-o functie de activare. Aceste noduri se pot stratifica pe mai multe nivele, intre care distingem nivelul de intrare, nivelele ascunse si nivelul de iesire. Fiecare nod din nivelul de intrare primeste in cazul nostru atribute specifice imaginilor multi-spectru, ca de exemplu o banda a Landsat ETM+. In [8] se mentioneaza ca un singur nivel ascuns este suficient pentru rezolvarea majoritatii problemelor de clasificare ce folosesc teledetectia. Pentru gasirea valorilor optime a parametrilor unei retele neuronale, ca si ponderile initiale sau rata de invatare, se pot folosii mai multe strategii. Cea mai eficienta abordare pentru rezolvare acestei probleme este tehnica incercare-si-eroare.

Cea mai importanta caracteristica a retelelor neuronale este abilitatea lor de a invata printr-un proces pe mai multe iteratii. In contextul sistemelor artificiale, invatarea poate fi definita ca procesul de actualizare a reprezentarii interne a sistemului ca si raspuns la stimuli externi in asa fel incat performanta unui cerinte specifice este imbunatatita. (Basheer and Hajmeer, 2000). Algoritmul de invatare defineste cum ponderile din retea sunt ajustate intre ciclurile succesive de antrenament, numite si *epochs*. Cu toate ca un numar de strategii de invatare au fost dezvoltate pentru modelul MLP(*Multi-layer perceptron*), cea mai populara strategie este algoritmul de invatare *Backpropagation*, cunoscut si sub numele de regula delta generalizata, algoritmul introdus de Rumelhart[9] in 1986. Metoda este bazata pe iteratii de invatare a *gradient descent* astfel incat datele de antrenament sunt prezentate retelei ca si

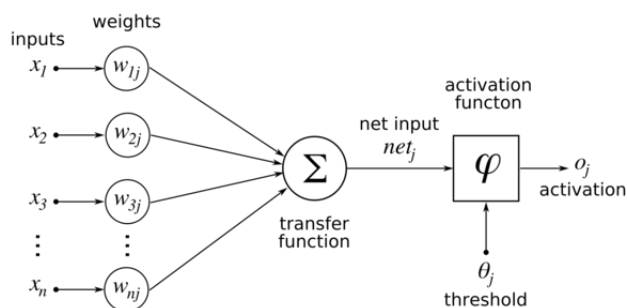


Fig. 2. Modelul unui nod de procesare intr-o retea neuronală. Valorile de intrare se insumeaza ponderat dupa care sunt trimise unei functii de activare.

date de intrare/iesire iar eroare este propagata din spate, de la nivelul de iesire catre cel de intrare. Acest proces se repeta pana cand eroarea este reduca la un nivel acceptabil predefinit.

C. Aplicatie interactiva pentru afisarea rezultatelor

Utilizatorii vor putea interactiona cu sistemul printr-o aplicatie ce permite observarea si extragerea de informatii pe baza rezultatelor clasificarii. Aplicatia se adreseaza urmatoarelor categorii de utilizatori:

- (1) Experti care lucreaza in domeniul umanitar. Food and Agricultural Organization(FAO), World Food Program(WFP) sunt agentii ale United Nations care muncesc pentru combaterea fenomenului de crize alimentare. Acesti experti au nevoie de date curente si istorice pentru a lua decizii. Ei au de obicei o experienta considerabila in interactiunea cu sisteme software, in special cu cele pentru redactarea rapoartelor(procesare de text) sau calcul tabelar(gen Excel).
- (2) Angajati guvernamentali din tari sub-dezvoltate. Acesti utilizatori au in general un nivel bun in interactiunea cu aplicatii software. In schimb, limbile vorbite in administratia acestor tari variaza, ceea ce cere ca sistemul sa fie localizabil.
- (3) Fermieri care doresc sa monitorizeze culturile si sa estimeze productia. Acesti utilizatori au o interactiune modesta cu aplicatii software.

Aplicatia va trebui sa suporte urmatoarele scenarii de utilizare:

- Stabilirea unei zone geografice de interes. Utilizatorii vor putea selecta o locatie geografica prin: navigarea (drag-and-drop) directa pe harta geografica, selectarea unei tari si regiuni dintr-o lista predefinita sau inserarea unor cuvinte cheie in casuta de cautare.
- Selectarea filtrului de timp. Utilizatorii vor putea afisa datele relevante pentru o perioada de timp. Acest lucru se va realiza prin intermediul unor casute de filtrare ce afiseaza data initiala si data finala a perioadei de timp.
- Selectarea tipului de recolte agricole. Utilizatorii vor putea selecta tipul de recolte agricole din liste construite contextual pe baza locatiei geografice.
- Generarea de rapoarte. Utilizatorii vor putea genera rapoarte grafice ce arata evolutia stadiului culturii pe o perioada de timp. Aceste rapoarte vor contine serii multiple si vor fi complementate cu date in format tabelar.
- Comparatia a doua momene de timp. Utilizatorii vor putea compara vizual si tabelar stadiul culturilor in doua momente de timp.
- Exportul de date. Utilizatorii vor putea exporta datele filtrate in format .csv sau .xlsx pentru a fi folosite in alte aplicatii software de calcul.

D. Arhitectura Sistemului

Arhitectura sistemului este prezentata in figura (3) si contine 3 mari componente principale: aplicatie pentru interactiunea cu utilizatorul, nivelul de servicii si nivelul de date.

Interfata cu utilizatorul consta intr-o aplicatie Web ce permite interactiunea concomitenta a mai multor useri pe

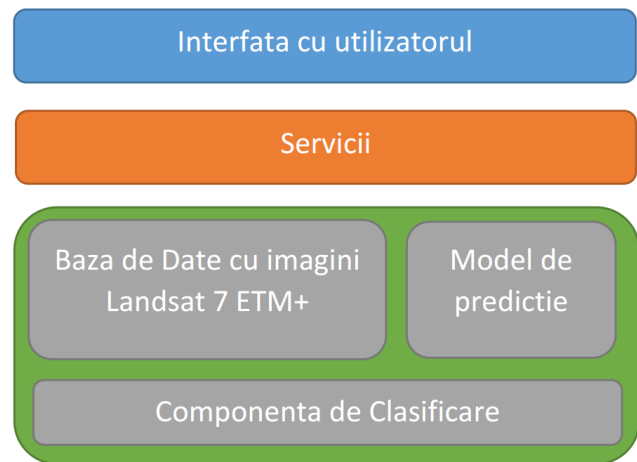


Fig. 3. Arhitectura sistemului

baza credentialelor. Sub-modulele aplicatiei interactive sunt delimitate dupa functiile pe care acestea le au.

Nivelul de servicii va rula pe un mediu distribuit, existand mai multe servere de procesare dintre care doar unul are rolul de Master. Request-urile ce vin catre acest serviciu vor fi balansate catre toate nodurile de procesare in mod egal printr-o tehnica *round robin*. In interiorul acestui nivel, cea mai importanta functionalitate o are componenta de caching. Dorim sa economisim timpul de procesare prin stabilirea unui threshold de memorie ce va fi dedicat operatiilor *Cache Hit* si *Cache Miss*. Datele adaugate in Cache vor avea un timp de expirare pre-definit.

Nivelul de date consta intr-o baza de date ce stocheaza fisierele imagine si varianta lor preprocesata. Tot la acest nivel distingem si componenta modelului de predicție. Acest model este antrenat *offline* prin folosirea componentei de clasificare. Este indicat ca serverul responsabil pentru clasificare sa fie echipat si cu procesoare GPU.

IV. CONSIDERATII TEHNOLOGICE

Imaginile satelitare sunt stocate pe hard-disc, partitionate pe foldere si indexate dupa nume pentru a optimiza gasirea si incarcare lor. Deoarece o singura imagine poate ajunge la peste 100 Mb, acestea sunt arhivate in grupuri de diverse marimi. Rezultatele pre-procesarii acestor imagini, vor fi stocate in fisiere text, valorile fiind delimitate prin virgula (fisiere csv, *Comma Separated Values*).

Codul pentru antrenarea modelului este scris in GNU Octave. Acesta este un limbaj interpretat, in principal folosit pentru calcule numerice. Oferă capabilitati de solutii numerice pentru probleme liniare si non-liniare. Contine de asemenea un pachet ce permite vizualizarea si manipularea datelor. De obicei Octave este folosit dintr-o interfata linie de comanda, dar poate fi folosit si in scrierea de programe non-interactive. Sintaxa Octave este foarte similara cu Matlab ceea ce face ca programele si fie portabile.

Fig. 4. Optiunea filtrului de locatie geografica.

Fig. 5. Optiunea filtrului pentru perioada de timp.

Fig. 6. Optiunea filtrului pentru tipurile de culturi agricole.

Implementarea nivelului de servicii este realizata cu limbajul C# pe baza framework-ului .NET. Aceste servicii ofera o interfata programatorilor pe baza unor API-uri RESTful. Pentru accesarea APIurilor de folosesc metodele standard HTTP: GET, PUT si POST. Comunicarea client-server este constransa de faptul ca nici un context al vreunui client sa fie stocat pe server intre request-uri, ceea ce face ca acest protocol sa nu tina cont de stare.

Aplicatia interactiva este programata folosind framework-ul MVC oferit de ASP.NET. Partile de interactiune ce necesita procesari pe masina client sunt realizate prin Javascript si JQuery. Se foloseste intensiv tehnologia AJAX (Asynchronous JavaScript and XML) prin care aplicatia Web poate trimite si receptiona date de la server in mod asincron, fara a interfera cu afisajul si comportarea paginii existente. Pentru imbunatatirea calitatii stilistice si pentru optimizarea timpului de lucru s-a decis folosirea framework-ului Bootstrap oferit de Twitter.

Mediile de dezvoltare folosite sunt Microsoft Visual Studio Ultimate si Microsoft SQL Server Studio Management 2013.

V. PROTOTIP

A. Interfata cu Utilizatorul

Bazat pe cerintele descrise in sectiunea II.C si consideratiile tehnologice din sectiunea IV, un prototip a fost implementat pentru aplicatia interactiva. Acest prototip implementeaza toate functionalitatile nivelului "Interfata cu utilizatorul". In schimb, interactiunea cu nivelul imediat inferior, cel al serviciilor, nu este veritabila. Se utilizeaza un set de date predefinit, iar din acest motiv utilizatorii aplicatiei prototip pot face doar anumite selectii in cadrul interfetei.




Fig. 7. Animatia afisata utilizatorilor pentru a semnala starea de procesare.

Figura 4 prezinta ecranul principal al aplicatiei. In partea de sus a ecranului gasim butoanele meniului principal, prin intermediul caruia utilizatorii pot selecta locatia geografica, perioada de timp, categoriile de culturi agricole considerate si tipul raportului. Tot in bara de sus, in partea dreapta se prezinta numele user-ului din sesiunea curenta. Imediat sub acest meniu se afiseaza o casuta de informatie cu optiunile selectate de user. Aceasta este importanta deoarece utilizatorul poate vedea informatiile filtrelor fara a mai activa butoanele meniului, salvand un numar de 5 click-uri.

Harta prezinta diferitele tipuri de culturi intr-un container interactiv. Utilizatorul poate folosi butoanele hartii sau direct mousul pentru a realiza operatiile de *zoom-in*, *zoom-out* sau mutarea zonei de interes pe harta. Dupa fiecare astfel de operatie, in timpul necesar calcularii si afisarii noilor date se prezinta utilizatorului o animatie ce indica incarcarea noilor date.

In partea din dreapta a hartii se prezinta informatii in valori numerice despre culturile afisate. Se prezinta totalul suprafetei acoperite cu culturi agricole impreuna cu procentajul aferent. La fel se procedeaza si pentru fiecare tip de cultura, adaugand si un index de culoare pentru a le putea identifica pe harta. Valorile se prezinta si printr-un grafic *bar-chart*, pentru a permite o comparatie vizuala. Sub aceste date, sunt oferite optiuni pentru printare a rezultatelor sau salvarea lor in format tabelar.

B. Analiza euristica a uzuabilitatii

Neilsen(include referinta) a definit un set the 10 principii pentru design-ul interactiunii. Acestea se numesc "euristici" deoarece sunt reguli generale si nu orientari specifice pentru uzuabilitate. Vom observa in cele ce urmeaza aplicarea acestor principii pe design-ul interactiunii in cadrul aplicatiei noastre:

1) *Vizibilitatea starii sistemului*: Sistemul trebuie intotdeauna sa tina utilizatorii informati despre starea sa, prin feedback relevant in timp rezonabil. Figura 5 evidenteaza mesajul afisat utilizatorilor atunci cand interactiunea cu o parte din aplicatie este blocata de starea de procesare.

2) *Echivalenta intre sistem si lumea reala*: Aceasta cerinta euristica propune ca sistemul sa vorbeasca aceasi limba sau sa utilizeze concepte familiare pentru utilizator. Aplicatia noastra

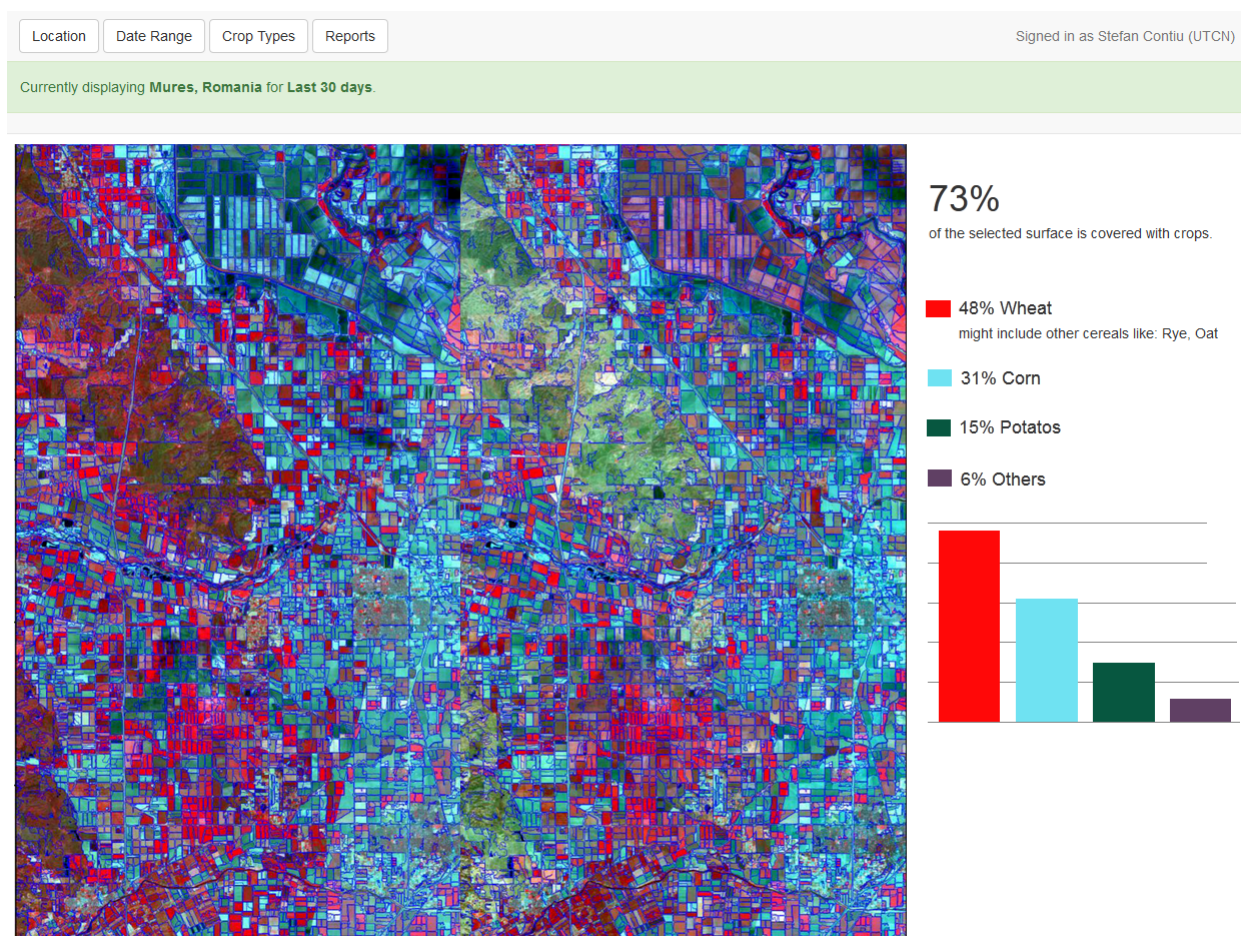


Fig. 8. Interfata aplicatiei interactive pentru vizualizare culturilor.

vizualizeaza informatiile in aceasi maniera ca softurile GIS (*Geographical Information Systems*) familiare pentru utilizatorii tinta. De asemenea terminologia tipului culturilor agricole folosite precum si regiunile, sub-regiunile geografice sunt echivalente cu termenii folositi de utilizatori in lumea reala.

3) *Controlul si libertatea utilizatorilor*: Uneori utilizatorii selecteaza functionalitati din greseala, avand nevoie de un control ce semnaleaza foarte clar iesirea din aceasta stare. In momentul in care un utilizator realizeaza ca a facut o selectie gresita a filtrelor si sistemul este in starea de procesare, acesta poate abandona si revenii la starea anterioara prin actionarea link-ului 'Cancel request' (exemplificat si in figura 5).

4) *Consistentia si standarde*: Utilizatorii nu ar trebuie sa puna la indoiala daca cuvinte, stari sau actiuni diferite in-seamna acelasi lucru. Pentru aceasta am convenit ca toate actiunile si termenii identici sa fie denumiti similar pe tot parcursul aplicatiei.

5) *Preventia erorilor*: Este de preferat ca utilizatorilor sa li se prezinte mesaje de eroare semnificative, prevenind probleme ce pot aparea. In cadrul aplicatiei noastre inconsistenta datelor pre-procesate poate naste asemenea erori. In acest caz utilizatorilor li se va afisa un mesaj prin care sunt anuntati ca datele selectate nu sunt disponibile momentan.

6) *Folosirea recunoasterii fata de reamintire*: Am preferat ca utilizatorii sa nu fie nevoiti sa isi aminteasca informatii care sunt ascunse in casutele pentru filtre, si pentru aceasta afisam o bara cu optiunile selectate chiar si atunci cand casutele filtru sunt inchise. De asemenea utilizatorilor li se propun liste cu optiuni astfel incat sa poata recunoaste si selecta filtrele dorite.

7) *Flexibilitate si eficienta*: Aplicatia interactiva este destul de flexibila si eficienta incat sa poata fi folosita atat de utilizatori neexperimentati cat si de cei experimentati.

8) *Design estetic si minimalist*: Am construit aplicatia noastra in asa fel incat sa nu contina informatii care sunt irelevante sau sunt necesare foarte rar.

9) *Ghidarea utilizatorilor pentru recunoasterea, diagnosticarea si revenirea din stările de eroare*: In cadrul aplicatiei noastre mesajele de eroare sunt exprimate in limbaj specific utilizatorilor si nu in coduri specifice limbajului de programare. De fiecare data cand este prezentata o eroare se prezinta si o sugestie de revenire la o stare anterioara. Acest functionalitate este posibila prin stocarea in variabilele de sesiune a ultimei actiuni a utilizatorului.

10) *Ajutor si documentatie*: Desi aplicatia poate fi folosita intuitiv fara a fi necesara documentatia, am preferat sa oferim o pagina de ajutor in care utilizatorii pot cauta informatii dupa

anumite cuvinte cheie sau actiuni. Sugestiile de ajutor sunt redactate in pasi concreti si concisi in descriere.

VI. CONCLUZII

In aceasta lucrare am prezentat un sistem ce permite monitorizarea si vizualizarea culturilor agricole, un proces crucial in prevenirea crizelor de hrana in tarile sub-dezvoltate. Am prezentat cum acest proces a fost automatizat prin folosirea unui algoritm de invatare supervizata bazat pe retele neuronale artificiale. Am prezentat si o aplicatie interactiva prin care utilizatorii pot vizualiza si interpreta rezultatele clasificarii.

Pentru antrenarea modelului am folosit imaginile multi-spectrale provenite de la satelitul Landsat 7+ ETM. Imaginile multi-spectrale sunt folosite cu succes in domeniul agriculturii de precizie datorita semnaturii spectrale create de fiecare tip de planta sau cultura agricola.

Aplicatia interactiva ce am prezentat-o respecta indicatiile si cerintele forumale in literatura de specialitate pentru designul aplicatiei interactive. Am parcurs cele 10 euristici formulate de Nielsen si am descris pentru fiecare modul de satisfacere din cadrul aplicatiei noastre.

REFERENCES

- [1] J. Nielsen, "Enhancing the explanatory power of usability heuristics", Proc. ACM CHI'94 Conf. (Boston, MA, April 24-28), 152-158, 1994.
- [2] T. Kazvoglou, "Increasing the accuracy of neural network classification using refined training data", Environmental Modelling & Software, vol. 24, no. 7, pp. 850-858, 2009.
- [3] H. Noh, Q. Zhang, B. Shin, S. Han, and L. Feng, "A neural network model of maize crop nitrogen stress assessment for a multi-spectral imaging sensor", Biosystems Engineering, vol. 94, no. 4, pp. 447-485, 2006.
- [4] Qin, J., Chao, K., Kim, M. S., Lu, R., & Burks, T. F., "Hyperspectral and multispectral imaging for evaluating food safety and quality", Journal of Food Engineering, 118(2), 157-171, 2013.
- [5] Zhang, B., Huang, W., Li, J., Zhao, C., Fan, S., Wu, J., & Liu, C., "Principles, developments and applications of computer vision for external quality inspection of fruits and vegetables: A review", Food Research International, 62, 326-343, 2014.
- [6] Nowatzki, J., Andres, R., & Kylo, K., "Agricultural Remote Sensing Basics", 2004.
- [7] Tso, B., Mather, P.M., "Classification Methods for Remotely Sensed Data", Taylor & Francis, London, 2001.
- [8] Mas, J.F., Flores, J.J., "The application of artificial neural networks to the analysis of remotely sensed data", International Journal of Remote Sensing 29(3), 617-663, 2008.
- [9] Rumelhart, D.E., McClelland, J.L., PDP Group, "Parallel Distributed Processing: Explorations in the Microstructure of Cognition : Foundations", MIT Press, London, 1986.